MODEL COMPRESSION REVIEW

26+ 组实验后的硬结论：参数更少 ≠ GPU 更快

统一口径：RTX 3090 Ti · 640 · batch=1 · fused FP16 · paired AB/BA · 3,606 图完整验证

实验路线地图

分辨率 512 KD	7.001 > 6.905 ms	0.633 / 0.474	FAIL
通道剪枝 参数最多 −52%	延迟 −1.23% ~ +0.08%	部分精度≈0	FAIL
BN-scale 稀疏精度保持	物理剪枝不加速	0.661 / 0.512 → 崩溃	FAIL
串行深度 Box d1 / P3 C2f	快 11.92% / 10.56%	0.633/0.474 · 0.634/0.460	ACC FAIL
ClassLite 48 / 52 / 56 ch	快 12.95% / 10.54% / 9.86%	52ch 最佳 0.625/0.468	ACC FAIL
P5 串行深度 backbone + neck C2f n=0	5.945 → 5.063 ms · 快 14.83%	0.662 / 0.496	ALL PASS
部署分支 删除 one-to-many	参数 −26.96% · 延迟 −0.19%	0.665 / 0.514 等价	SHIP

双门禁

GATE 1 · SPEED

≥ 10%

paired fused-FP16 延迟下降

GATE 2 · ACCURACY

Box ≥ 0.64761
Pose ≥ 0.49455

双门禁同时通过

1 个结构候选

参数量不是 GPU latency 的可靠代理

真正有效：减少串行 kernel / 卷积层

BASELINE

0.665 / 0.515
Box / Pose mAP50-95

7.147 → 5.727 ms
one-to-one + fuse + FP16（部署优化，不计入剪枝收益）

−19.88%

MODEL COMPRESSION REVIEW

两组最佳方案：体积优先与速度—精度平衡

两组均可交付；P5-Zero 首次同时通过精度、速度与显存门禁

SHIP

Deployment-only 分支裁剪

删除 one-to-many，保留完整 one-to-one 推理图

-26.96% 参数量

-26.59% checkpoint 文件

-8.99% 推理峰值显存

0.665 / 0.514 Box / Pose · 完整 3,606 图

-0.19% paired latency（基本不变）

BIT-EXACT `dense output max/mean error = 0`

工程定位

✓ 立即交付：模型体积 / CUDA 内存优化

✓ 精度与输出等价，风险边界清晰

× 不宣称显著 latency 收益

SHIP

P5-Zero 平衡结构

仅移除 backbone/neck P5 内部 bottleneck，完整保留 P3/P4 与任务塔

5.94537 baseline ms → **5.06345** candidate ms **-14.83%** paired latency

0.66254 / 0.49592 最佳 Box / Pose

-15.14% 参数量

SPEED PASS ACCURACY PASS MEMORY PASS

精度余量 / 显存收益

Box +0.01493 Pose +0.00137 Peak -5.02%

完整 3,606 图验证；paired AB/BA；无 TensorRT

决策：SHIP deployment-only · SHIP P5-Zero 平衡结构

MODEL COMPRESSION REVIEW

工程决策：P5-Zero 通过三门禁，进入可复用交付

从失败机制到成功结构，固化可复用的模型压缩搜索与验证规则

EVIDENCE → RULES → NEXT SEARCH

01

失败机制

- **参数量不是 latency 代理**
  -52% 参数仍可能不加速
- **分类分数牵动双任务 mAP**
  Box / Pose 同时受置信度影响
- **低分辨率层更适合减深**
  P5 减层跨过三门禁，P3/P4 不动

02

已证实的工程规则

- **冻结参数 ≠ 冻结行为**
  必须固定 BN running statistics
- **拒绝简单 tensor slicing**
  使用投影折叠 / 定向搬运 / padding
- **速度先 gate，再投入训练**
  paired AB/BA，避免时钟偏差

03

下一步结构搜索

- **交付 P5-Zero**
  冻结结构、配置与最终 checkpoint
- **复验跨设备稳定性**
  保持 PyTorch fused FP16 口径
- **后续仅做小步消融**
  每步重新执行延迟 + 精度 + 内存

可靠性边界

LATENCY	同进程 paired AB/BA · fused FP16 · batch=1 · 640	ACCURACY	3,606 图 · 11,569 实例 · Box/Pose/PCK/NME
MEMORY	独立进程测模型加载 / 输入后 / 推理峰值	RECORD	CSV / JSON / 日志 / 停止原因全部留存

SHIP · deployment-only branch pruning

SHIP · P5-Zero balanced pruning