MODEL COMPRESSION REVIEW

26+ 组实验后的硬结论：参数更少 ≠ GPU 更快

统一口径：RTX 3090 Ti · 640 · batch=1 · fused FP16 · paired AB/BA · 3,606 图完整验证

实验路线地图

分辨率 512 KD	7.001 > 6.905 ms	0.633 / 0.474	FAIL
通道剪枝 参数最多 −52%	延迟 −1.23% ~ +0.08%	部分精度≈0	FAIL
BN-scale 稀疏精度保持	物理剪枝不加速	0.661 / 0.512 → 崩溃	FAIL
串行深度 Box d1 / P3 C2f	快 11.92% / 10.56%	0.633/0.474 · 0.634/0.460	ACC FAIL
ClassLite 48 / 52 / 56 ch	快 12.95% / 10.54% / 9.86%	52ch 最佳 0.625/0.468	NEAREST
部署分支 删除 one-to-many	参数 −26.96% · 延迟 −0.19%	0.665 / 0.514 等价	SHIP

双门禁

GATE 1 · SPEED

≥ 10%

paired fused-FP16 延迟下降

GATE 2 · ACCURACY

Box ≥ 0.64761
Pose ≥ 0.49455

双门禁同时通过

0 个结构候选

参数量不是 GPU latency 的可靠代理

真正有效：减少串行 kernel / 卷积层

BASELINE

0.665 / 0.515
Box / Pose mAP50-95

7.147 → 5.727 ms
one-to-one + fuse + FP16（部署优化，不计入剪枝收益）

−19.88%

MODEL COMPRESSION REVIEW

两组最佳方案：一组可交付，一组仍是研究候选

收益目标不同：体积/显存压缩 ≠ 显著延迟优化

SHIP

Deployment-only 分支裁剪

删除 one-to-many，保留完整 one-to-one 推理图

-26.96% 参数量

-26.59% checkpoint 文件

-8.99% 推理峰值显存

0.665 / 0.514 Box / Pose · 完整 3,606 图

-0.19% paired latency（基本不变）

BIT-EXACT `dense output max/mean error = 0`

工程定位

✓ 立即交付：模型体积 / CUDA 内存优化

✓ 精度与输出等价，风险边界清晰

× 不宣称显著 latency 收益

RESEARCH

ClassLite52 串行分类塔

保留第一组 DS block；第二组替换为 52ch pointwise

6.02302 baseline ms → **5.38792** candidate ms **-10.54%** paired latency

0.62507 / 0.46795 最佳 Box / Pose

-4.28% 参数量

SPEED PASS ACCURACY FAIL

距离精度线

Box -0.02254 Pose -0.02660

12 轮头部监督已确认平台，不应继续重复微调

决策：SHIP 内存压缩 · HOLD ClassLite52 延迟候选

MODEL COMPRESSION REVIEW

工程决策：先交付内存压缩，停止重复微调 ClassLite52

从失败机制出发，形成可复用的模型压缩门禁与下一步搜索策略

EVIDENCE → RULES → NEXT SEARCH

01

失败机制

- **参数量不是 latency 代理**
  -52% 参数仍可能不加速
- **分类分数牵动双任务 mAP**
  Box / Pose 同时受置信度影响
- **异构 KD 可能限制恢复**
  纯监督最好：0.62507 / 0.46795

02

已证实的工程规则

- **冻结参数 ≠ 冻结行为**
  必须固定 BN running statistics
- **拒绝简单 tensor slicing**
  使用投影折叠 / 定向搬运 / padding
- **速度先 gate，再投入训练**
  paired AB/BA，避免时钟偏差

03

下一步结构搜索

- **保留完整分类塔**
  避免当前最主要精度瓶颈
- **从骨干 / 颈部减少串行 kernel**
  优先可近恒等初始化的小改动
- **重新执行三重门禁**
  延迟 + 完整精度 + CUDA 内存

可靠性边界

LATENCY	同进程 paired AB/BA · fused FP16 · batch=1 · 640
ACCURACY	3,606 图 · 11,569 实例 · Box/Pose/PCK/NME
MEMORY	独立进程测模型加载 / 输入后 / 推理峰值
RECORD	CSV / JSON / 日志 / 停止原因全部留存

SHIP · deployment-only branch pruning

HOLD · ClassLite52 until accuracy gate passes